第5章 并发性: 互斥和同步

5.1 互斥: 软件解决方法

5.2 并发的原理

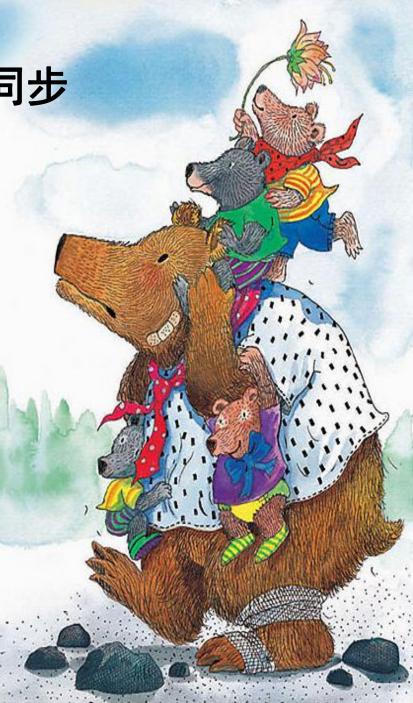
5.3 互斥: 硬件的支持

5.4* 信号量

5.5* 管程

5.6 消息传递

5.7 读者一写者问题





为什么要考虑"互斥与同步"?

- ◆ 在单CPU、多CPU及分布式系统中,有多个进程 并发甚至并行执行。对资源的共享和竞争,使得 并发进程之间相互制约。
 - 由于共享某些资源(如变量、文件、设备等),一个进程的执行可能影响其它进程的执行结果。
 - 与同一共享资源有关的程序段分散在各进程中, 且各进程的相对执行速度不可预知。
 - 由于每次并发执行顺序不同,并发进程的执行结果将不确定(不可再现),甚至可能导致错误;但发生错误的精确条件和执行顺序很难再现,导致错误(bug)很难调试定位。

共享资源x

与并发相关的一些术语

- ◇ 临界资源: 一次仅允许一个进程独占使用的不可剥夺资源。
- ◆ 临界区: 进程访问临界资源的那段程序代码。
 一次仅允许一个进程在临界区中执行。
- ◆ 互斥: 当一个进程正在临界区中访问临界 资源时,其它进程不能进入临界区。
- 同步:合作的并发进程需要按先后次序执行。 例如:一个进程的执行依赖于合作进程的消息或信号。 当一个进程没有得到来自于合作进程的消息或信号时需 阻塞等待,直到消息或信号到达才被唤醒。
- ◆ 死锁: 多个进程全部阻塞,形成等待资源的循环链。
- ◆ 饥饿: 一个就绪进程被调度程序长期忽视、不被调度执行; 一个进程长期得不到资源。

5.2 并发的原理



5.2.1 一个简单的例子

```
void echo()
{
① chin=getchar();
② chout=chin;
③ putchar(chout);
}
echo()是一个共享的键盘字符回显
过程,所有进程都可以调用echo()。
chin和chout是全局共享变量。
}
```

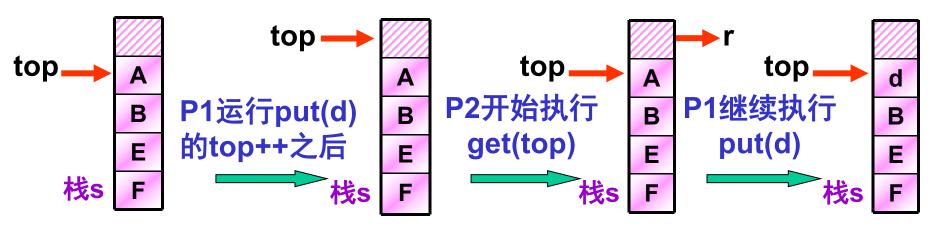
- ◆ 在单CPU和多CPU系统中,多个进程对全局变量的访问 不加以控制时,可能导致错误。
 - 如:P1执行①后被中断,此时chin值为x; 之后P2执行①②③后结束,此时chin值为y; 最后P1被恢复调度,执行②③,输出y。
- ◆ 解决: 一次只允许一个进程在echo中执行。当P2企图进入echo时将被阻塞,待P1退出echo后,P2才能进入。

5.2 并发的原理

- ◆ 例:全局共享的堆栈s[]及栈顶指针top,将数据压栈的put(d)和取栈顶数据的get(top)可被P1、P2并发执行。

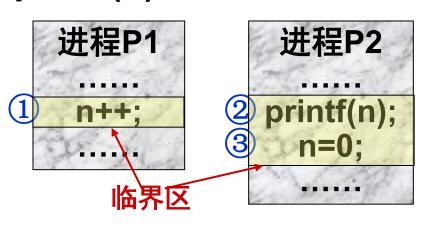
```
void put(int d)
{ top++;
    s[top]=d;
}
```

```
int get(int top)
{ int r;
    r=s[top];
    top--;
    return r;
}
```



5.2.2 竞争条件

- ◎ 竞争条件:多个线程或进程在读写共享数据时, 最终结果依赖于它们的指令执行顺序。



不同执行顺序:

①②③: 输出6, n=0;

②③①: 输出5, n=1;

②①③: 输出5, n=0;

◇ 上面的3条语句执行顺序: ①②③和②③①都认为是正确的, 但②①③被认为是错误的。

5.2.3 操作系统关注的问题





- ◆ 并发进程间应实现互斥与同步。
- ◈ OS应该:
 - 跟踪不同进程,管理进程状态;
 - 为每个活跃进程分配和释放各种资源;
 - 保护每个进程的数据和物理资源,避免其它 进程的有意无意干涉;
 - 一个进程的功能和输出结果正确与否,应与 其它并发进程的相对执行速度无关。

5.2.4 进程的交互



并发进程间的三种交互关系: (一)

- ◈ 进程间的资源竞争: 进程间相互不知道对方的存在
 - 竞争使用CPU、存储器、独占式设备(如打印机)等。
 - 竞争进程间没有任何信息交换,但执行过程可能受到其它竞争者的影响。如试图使用已分配设备时将阻塞。
 - 竞争进程互斥访问临界资源,一次只允许一个进程在临界区中执行,其它试图进入临界区的进程将阻塞。但可能导致饥饿和死锁。

```
/* PROCESS 1 */
                                                                    /* PROCESS n */
                           entercritical 和 exitcritical
void P1
                                                                   Pn
                           保证临界区的互斥执行。
                                                               while (true) {
 while (true) {
                                   eceding code */;
                                                                 /* preceding code */;
   /* preceding code /:
   entercritical (Ra);
                              entercritical (Ra);
                                                                 entercritical (Ra);
                              / critical section >>
                                                                 critical section /;
   critical section >/;
   exitcritical (Ra):
                              exitcritical (Ra):
                                                                 exitcritical (Ra);
   /* following code */;
                             /* following code */;
                                                                 /* following code */;
```

5.2.4 进程的交互



并发进程间的三种交互关系: (二)

- ◈ 进程间通过共享的合作: 进程间接知道对方的存在
 - 进程之间共享某些资源(如共享变量、文件、数据 库等),但不能确切知道对方。
 - 多个进程可以同时读一个数据项,但须互斥"写"。
 - 多个进程读写共享数据时,需保证数据一致性。
 - ■顺序执行每个进程会使共享数据保持一致性, 但不同进程对共享数据交替读写会导致错误。 如"竞争条件"节的例子。

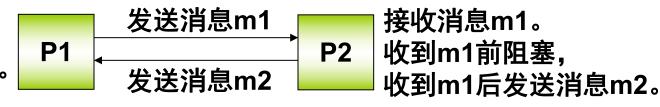
5.2.4 进程的交互



并发进程间的三种交互关系: (三)

- ◈ 进程间通过通信的合作: 进程直接知道对方的存在
 - 多个进程通过进程ID互相通信(发送消息和接收消息),实现同步和协调各种活动。
 - 传递消息时,进程间未共享资源,则不需要互斥。 但可能出现饥饿和死锁。

接收消息m2。 收到m2前阻塞。



5.2.5 互斥的要求



- ◆ 有限等待:请求进程应在有限的等待时间内进入临界区,不能造成进程死锁或饥饿。
 - 一个进程驻留在临界区中的时间是有限的。
- ◆ 有空让进:当临界区空闲时,请求进程可立即进入。
- ◇ 让权等待: 进程不能进入临界区时, 应释放处理器, 避免忙等。
 P2 P3

Question:



- 1、下列属于临界资源的是____。
- A. 磁盘存储介质

B全局的公共队列

C. 局部变量

D. 可重入的代码

<mark>可同时被多个进</mark> 程执行的纯代码

- 2、一个正在访问临界资源的进程由于申请等待I/O操作 而被中断时,它。
- A. 可以允许其它进程进入该进程的相关临界区
- B. 不允许其它进程进入任何临界区
- C. 不允许其它进程抢占处理器
- D/可以允许其它进程抢占处理器,但不能进入相关临界区

5.1 互斥: 软件解决方法



5.1.1 Dekker算法 1965年

```
共享变量初值: turn = 0;
turn=i ⇒ Pi正在临界区中运行
```

```
Process Pi
while(true)
{ while ( turn != i ) ;
/* 临界区 */
turn = j;
}
```

两进程P0和P1互斥 交替运行,但不满 足有空让进条件。

```
共享变量初值: flag [0] = flag [1] = false; flag[i]=true ⇒ Pi 可以进入临界区或正在临界区中
```

```
Process Pi
while(true)
{ while (flag[j]);
flag[i] = true;
/* 临界区*/
flag[i] = false;
}
```

BUG: P0和P1可能同时进入临界区

```
Process Pi
while(true)
{ _flag[ i ] = true;
while (flag[ j ]) ;
/* 临界区 */
flag [ i ] = false;
}
```

BUG: P0和P1可能互相等待(死锁)

```
flag[i] =true && turn=i

⇒ Pi 正在临界区中运行
```

```
Process Pi
while(true)
{ flag[ i ] = true;
    while (flag[ j ])
    { if (turn==j)
        { flag[ i ]=false;
            while (turn==j) ;
            flag[ i ]=true; }
    }
    /* 临界区 */
    turn=j;
    flag [ i ] = false;
}
```

正确,只适于两 个进程的互斥。

5.1.2 Peterson算法 1981年

```
共享变量初值:
flag [0] = flag [1] = false, turn = 0;
flag[i] =true && turn= i ⇒ Pi 正在临界区中运行
```

满足"强制互斥,有限等待,有空让进"三个要求,但只适于两个进程的互斥。

```
Process P<sub>i</sub>
while (true)
{ flag [ i ] = true; turn = j;
while (flag [ j ] && turn == j) ;
/* 临界区 */
flag [ i ] = false;
} // 只适于P0, P1的互斥
```

5.3 互斥: 硬件的支持一用硬件实现互斥

5.3.1 中断禁用

◈ 单CPU系统中,"关中断"可以实现临界区互斥。

```
while (true)
{
    /* 关中断 */;
    /* 临界区 */;
    /* 开中断 */;
    /* 其余部分 */;
}
```

- ◈ 不应该让用户关中断;
- ◆ 长时间关中断导致串行执行进程、 系统的执行效率低:

5.3.2 专用机器指令一实现互斥 >>

15

- ◈ 两种机器指令(原子地在一个指令周期内执行):
 - 比较和交换指令: compare_and_swap

```
int compare_and_swap (int *word, int testval, int newval)
{    int oldval;
    oldval = *word;
    if (oldval == testval) *word = newval;
    return oldval;
} 比较word和testval,相等时word赋值为newval。返回原word值。
```

一个临界资源一个bolt变量,初值为0(开锁)。bolt为0时资源可用;bolt为1时进程等待。进入临界区时bolt=1;退出临界区时bolt=0。

```
▋️用compare_and_swap实现互斥
```

比较和交换指令C&S机器指令一实现互斥



```
int compare_and_swap (int *word, int testval, int newval)
{ int oldval:
  oldval = *word;
  if (oldval == testval) *word = newval;
  return oldval;
} 比较word和testval,相等时word赋值为newval。返回原word值。
void P0
{ while (C&S(bolt, 0, 1) == 1)
      /* do nothing */;
  /* 临界区 */;
  bolt = 0;
  /* 其余部分 */;
void P1
{ while (C&S(bolt, 0, 1) == 1)
      /* do nothing */;
  /* 临界区 */;
  bolt = 0;
  /* 其余部分 */;
```

bolt初值=0。

设P0先运行, C&S(0,0,1)将bolt赋值=1; 返回bolt 旧值0; while条件 0==1 不成立, 结束while循环, 进入临界区。

P1开始运行, C&S(1,0,1)返回bolt值1; while条件 1==1 成立,重复执行while循环(忙等) 导致CPU效率低):

P0继续运行,退出临界区后将bolt赋值=0。

P1再次运行, C&S(0,0,1)将bolt赋值=1; 返回bolt 旧值0; while条件 0==1 不成立, 结束while循环, 进入临界区。退出临界区后将bolt赋值=0。

5.3.2 专用机器指令一实现互斥 >>

- ◈ 两种机器指令(原子地在一个指令周期内执行):
 - ◎ 交換指令: exchange

```
void exchange (int *register, int *memory)
{    int temp;
    temp = *memory;
    *memory = *register;
    *register = temp;
} 交换register和memory的值。
```

一个临界资源一个bolt变量,初值为0(开锁)。bolt为0时资源可用;bolt为1时进程等待。进入临界区时bolt=1;退出临界区时bolt=0。

用exchange实现互斥

```
void P(int i) /* 进程Pi 代码。共n个进程。*/
{ int keyi = 1; /* 每个进程有自己的keyi */
    while (true) {
        while (keyi == 1) exchange (&keyi, &bolt);
        /* keyi为1时,循环交换 */
        /* 临界区 */;
        bolt = 0; /* 退出临界区时开锁 */
        /* 其余部分 */;
    }
    忙等(自旋等待)
```

交换指令EX机器指令一实现互斥



```
void exchange (int *register, int *memory)
  int temp;
   temp = *memory;
   *memory = *register;
   *register = temp;
} 交换register和memory的值。
void P0
\{ int key0 = 1; \}
   while (key0 == 1)
      EX(&key0, &bolt);
/* 临界区 */;
  bolt = 0;
void P1
\{ int key1 = 1; \}
  while (key1 == 1)
     EX(&key1, &bolt);
/* 临界区 */;
  bolt = 0;
```

bolt初值=0。

设P0先运行,key0赋值=1; key0==1条件成立,交 换key0和bolt值,使key0=0,bolt=1; 再次判断循环 条件key0==1不成立,结束循环进入临界区。

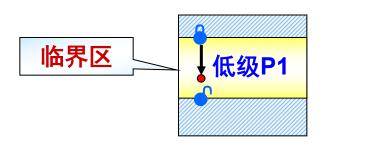
P1开始运行, key1赋值=1; key1==1条件成立, 交换key1和bolt值, 使key1=1, bolt=1; 再次判断循环条件key1==1仍然成立, 重复执行while循环(忙等导致CPU效率低);

P0继续运行,退出临界区后将bolt赋值=0。

P1再次运行, key1==1条件成立,交换key1和bolt 值,使key1=0,bolt=1;再次判断循环条件key1==1不成立,结束循环进入临界区。退出临界区后将bolt赋值=0。

5.3.2 专用机器指令一实现互斥 >>

- ◎ 这两种机器指令可以实现互斥。
 - 进程数量任意,适合于共享内存(要访问全局变量bolt) 的单CPU和多CPU系统。
 - 可支持多个临界区互斥。各临界资源有自己的"bolt"。
 - 忙等(也称自旋等待)消耗CPU时间,效率低。
 - 可能饥饿:多个进程等待进入临界区时,选择哪个等待 进程是随机的。
 - 可能死锁:如按优先级调度CPU时,设一低优先级的P1进入临界区后被中断,高优先级的P2抢占了CPU;P2试图使用同一临界资源时被拒绝且开始忙等循环;P1优先级低,无法被调度执行及退出临界区。此时P1和P2进入死锁状态。





5.4 信号量 semaphore *****



- ◈ 信号量:不要求忙等的同步互斥工具。
 - 只考虑计数信号量(V8图5.3, V9图5.6)。二元信号量 及互斥量略。
- ◆ 一个信号量表示一种资源。
- ◎ 当资源不可用时,进程将阻塞(避免忙等), 直到另一进程释放资源时才被唤醒。
- 信号量 s 只能被下面的两个原语访问:
 - semWait(s) 也称 P(s)操作, wait(s)
 - semSignal(s)也称 V(s)操作, signal(s)

1965年,荷兰,Dijkstra提出

5.4 信号量一信号量含义



- ◈用于互斥时, s初值为1, 取值为1~一(n-1)。
 - s=1时:有1个临界资源可用,一个进程可进入临界区。
 - s=0时: 临界资源已分配,一个进程已进入临界区。
 - s<0时: 临界区已被占用, |s|个阻塞进程正等待进入。
- ◈ 用于同步时, s初值将 >=0。
 - s>=0: 可用资源个数(或可进入临界区的进程个数)。
 - s<0 : 该资源的等待队列长度(阻塞进程个数)。
 </p>

5.4 信号量一semWait、semSignal含义

- ◆ semWait(s): 本进程请求分配一个资源。
- ◆ semSignal(s):本进程释放一个资源。
- ◈ semWait(s)、semSignal(s)操作必须成对出现。
 - 用于互斥时,位于同一进程内、临界区前/后;
 - 用于同步时,交错出现于两个合作进程内。
- 多个semWait()的次序不能颠倒,否则可能导致 死锁。用于同步的semWait(s1)应出现在用于互 斥的semWait(s2)之前。
- 参 多个semSignal()操作的次序可任意。



```
进程P: 进程Q: semWait(s); 临界区; 临界区; semSignal(s);
```



5.4 信号量一信号量原语的定义。



```
struct semaphore
{ int count; /* 信号量的值,实质是可用资源个数 */
  queueType queue; /* 因该信号量而阻塞的进程队列 */
}; /* 信号量定义(V8图5.3, V9图5.6)*/
```

```
semWait(semaphore s)
{
    s.count--;
    if (s.count < 0)
    {将当前进程放入s.queue;
        阻塞当前进程;
    }
}
    申请分配资源s
```

```
semSignal(semaphore s)
{
    s.count++;
    if (s.count <= 0)
    {从s.queue中移除进程P;
        将进程P插入到就绪队列;
    }
}

释放资源s
```

V8图5.3,V9图5.6

5.4.3 信号量的实现



- ◆ 怎样保证 semWait和semSignal 被原子地执行?
 - Compare&Swap指令:适用于多CPU系统(略)
 - 关中断方法:适用于单CPU系统

```
semWait(s)
{关中断;
 s.count - -;
 if (s.count < 0) {
  本进程放到s.queue阻塞;
 开中断:
```

```
semSignal(s)
{关中断;
 s.count++;
 if (s.count <= 0) {
  唤醒s.queue的队首进程;
 开中断;
```

5.4 信号量一强、弱信号量



- ◎ 当进程Q执行semSignal(s)释放资源时, 将唤醒一个阻塞进程并移出阻塞队列。
- ◈ 进程按照什么顺序从阻塞队列中移出?
 - ●FIFO:被阻塞时间最久的进程最先被移出。
- ◈ 强信号量:采用FIFO移出策略的信号量。
 - ◉不会导致饥饿。典型的信号量形式。

5.4.1 互斥一用信号量实现互斥

- ◆ 实现互斥:每个进程在进入临界区前,执行
 semWait(s);退出临界区后,执行semSignal(s)。
- ◆ 临界区内不应有可能引 起阻塞或死锁的因素。

```
进程P1:
semWait(s);
临界区1;
semSignal(s);
.....
```

```
const int n = /* 进程数 */;
semaphore s = 1; /*s初值=1*/
           /*进程Pi */
void P(int i)
   while (true) {
     semWait(s);
      /* 临界区 */;
     semSignal(s);
     /* 其它部分 */;
void main()  /*n个进程并发*/
{ parbegin (P(1), P(2), ..., P(n)); }
```

两个进程实现互斥例子



```
semWait(semaphore s)
{ s.count--;
  if (s.count < 0)
  {将当前进程放入s.queue;
  阻塞当前进程;
  }
}
```

```
semSignal(semaphore s)
{ s.count++;
  if (s.count <= 0)
  {从s.queue中移除进程P;
  将进程P插入到就绪队列;
  }
}
```

```
进程P1:
.....
semWait(s);
临界区1;
semSignal(s);
```

```
s初值=1;
```

P1先运行,执行 Wait(s) ,使得 $s \rightarrow 0$; 进入临界区1执行; 时间片超时后,让出CPU;

P2被调度执行, 执行 Wait(s), 使得 s→ -1; P2被阻塞;

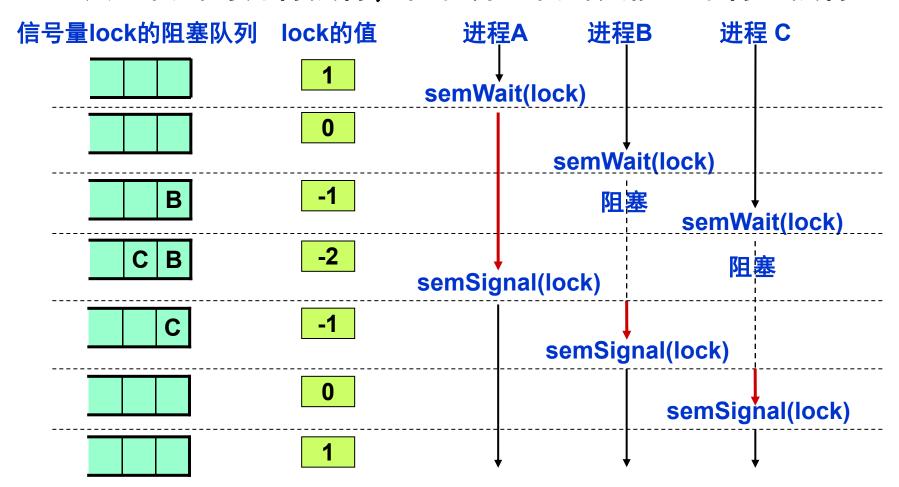
P1再次运行,执行 **Signal(s)** ,使得 **s→0** ;唤醒阻塞进程P2;运行完毕。

进程P2:
.....
semWait(s);
临界区2;
semSignal(s);
.....

P2再次运行,直接进入临界区2执行;之后再执行 Signal(s),使得 s→1;没有阻塞进程需要被唤醒;运行完毕。

5.4.1 互斥一用信号量实现互斥例

◆ 例:三个进程访问一个受信号量lock保护的临界资源。 其它代码可并行执行,但临界区代码只能"串行"执行。



5.4.1 互斥一用信号量实现同步

- ◎ 同步时,对每"一类资源"设一信号量s, 初值>=0,表示可用资源个数。
 - 资源:可以是同一物理资源的不同状态,如缓冲的空和满。对空缓冲和满缓冲分别设置信号量。
- ◆ 要求实现: P1已执行过A后, P2才能开始执行B。 设一信号量s, 初值为0。

```
■ Process P1:
do
{ .....
代码段 A;
semSignal(s);
}
```

```
■ Process P2:
do
{ semWait(s);
代码段 B;
......
```

```
例: S=0
P2先运行
semWait(s)
S=-1
P1再运行
semSignal(s)
S=0 唤醒P2
```

Question:



◆考虑5.1.2 竞争条件小节例,如何实现语句执行顺序为①②③或②③①?

若必须以①②③顺序执行: 若必须以②③①顺序执行:

则设一个用于同步的信号量s,初值为0。

```
进程P1
.....
n++;
semSignal(s);
.....
```

```
进程P2
.....
semWait(s);
printf(n);
n=0;
.....
```

```
进程P1
.....semWait(s);
n++;
```

```
进程P2
.....
② printf(n);
③ n=0;
semSignal(s);
```

若不强制要求P1或P2的执行顺序,则设一互斥信号量s,初值为1。

```
进程P1
semWait(s);
n++;
semSignal(s);
```

```
进程P2
semWait(s);
printf(n);
n=0;
semSignal(s);
```

5.4.1 互斥一semWait顺序不能颠倒

- ◈ 多个 semWait 操作的顺序不能颠倒. 否则可能 导致死锁。semSignal 的顺序可以颠倒。
- ◆ 例: 设 S 和 Q 是两个初值为1的信号量。

```
P1
                  P2
semWait(S);
                semWait(S);
semWait(Q);
                 semWait(Q);
semSignal(S);
                semSignal(Q);
semSignal(Q);
                 semSignal(S);
```

```
semWait(S);
                semWait(Q);
semWait(Q);
                semWait(S);
semSignal(S);
                semSignal(S);
semSignal(Q);
                 semSignal(Q);
```

正确顺序

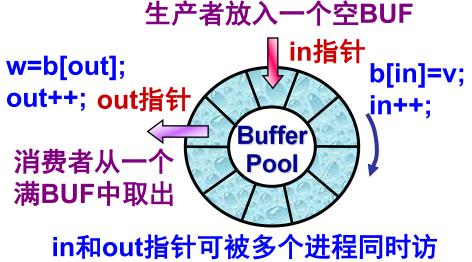
错误顺序

Question:如果一个糟糕的程序员漏写或多写了 semWait 或 semSignal,将会怎样?

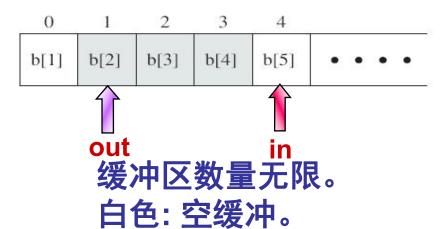
5.4.2 生产者/消费者问题



- ◈ 一组生产者进程产生数据,放到缓冲区。
- ◆ 一组消费者进程从缓冲区中取出数据使用。
 - 有限缓冲:假设缓冲池大小固定,包含k个缓 冲区。生产者和消费者共用一个循环缓冲池。
 - 无限缓冲:缓冲区数量无限制。



问修改, 故缓冲池需互斥访问。



灰色:有效的满缓冲。

5.4.2 生产者/消费者问题-有限缓冲



- ◆ 一组生产者进程和一组消费者进程共用一个 有sizeofbuffer个缓冲区的缓冲池来交换数据。
- ◈ 资源、约束条件及信号量设置:
 - 缓冲池一次只能让一个进程访问。(互斥) 设一信号量 s,初值为 1。
 - 生产者需要空缓冲来发送数据。(同步) 设一信号量 empty, 初值为 sizeofbuffer。
 - 消费者需要满缓冲来获取数据。(同步) 设一信号量 full,初值为 0。

5.4.2 生产者/消费者问题-有限缓冲



```
void producer()
  while (true) {
   生产一个数据;
   semWait(empty);
   semWait(s);
   把数据送到缓冲区;
   semSignal(s);
   semSignal(full);
```

```
void consumer()
  while (true) {
    semWait(full);
    semWait(s);
    从缓冲区中取出数据;
    semSignal(s);
    semSignal(empty);
    消费数据;
```

V8图 5.13, V9图 5.16

semSignal的顺序任意,但semWait的顺序不能颠倒。 用于同步的semWait()应出现在用于互斥的semWait()之前

Westion;这里,哪个是同步semWait,哪个是互斥semWait?

5.4.2 生产者/消费者问题 - wait顺序正确例



◈ 设2个生产者、2个消费者共用一个8缓冲的缓冲池。

P _{生1}	P _{生2}	P _{消1}	P _{消2}
 生产数据1;	 生产数据2;	 Wait(full);	 Wait(full);
Wait(empty); Wait(s);	Wait(empty); Wait(s);	Wait(s); 从缓冲取数x;	Wait(s); 从缓冲取数y;
放入缓冲; Signal(s);	放入缓冲; Signal(s);	Signal(s); Signal(empty);	Signal(s); Signal(empty);
Signal(full);	Signal(full);	消费数据x;	消费数据y;
			•••••

各信号量初值如下:

无论生产者、消费者以何顺序 交替执行,都可保证正确地同 步互斥。

5.4.2 生产者/消费者问题 - wait顺序颠倒例



♦ 设生产者wait颠倒:

```
P消
 P<sub>#</sub>
             Wait(full);
 生产数据;
             Wait(s);
 Wait(s);
             从缓冲取数x;
 Wait(empty);
 放入缓冲;
             Signal(s);
             Signal(empty);
 Signal(s);
             消费数据x;
 Signal(full);
信号量当前值如下。生产者
先运行,消费者后运行时将
死锁。
            s=1
      empty=0
          full=8
```

```
P<sub>+</sub> 执行 Wait(s), 使得 s→0;
P<sub>+</sub> 时间片超时,调度P<sub>ii</sub>执行;
P<sub>i</sub>执行Wait(full),使得 full→7;
P<sub>i</sub>执行Wait(s),使得 s→-1,P<sub>i</sub>阻塞;
调度P<sub>+</sub>执行;
P<sub>±</sub> 执行 Wait(empty), 使得 empty→-1,
P<sub>+</sub>阻塞;
两个进程发生死锁。
```

5.4.2 生产者/消费者问题 - wait顺序颠倒例



● 设消费者wait颠倒:

```
P<sub>#</sub>
              P消
 生产数据2;
             Wait(s);
            Wait(full);
 Wait(empty);
           从缓冲取数y;
 Wait(s);
 放入缓冲;
             Signal(s);
 Signal(s);
             Signal(empty);
             消费数据y;
 Signal(full);
信号量当前值如下。消费者
先运行,生产者后运行时将
死锁。
           s=1
      empty=8
         full=0
```

```
P<sub>ii</sub>执行 Wait(s),使得 s→0;
P<sub>ii</sub> 时间片超时,调度P<sub>+</sub>执行;
P<sub>+</sub>执行Wait(empty),使得 empty→7;
P<sub>+</sub>执行Wait(s),使得 s→-1,P<sub>+</sub>阻塞;
调度P<sub>消</sub>执行;
P<sub>ii</sub>执行 Wait(full),使得 full→-1,
P<sub>消</sub>阻塞;
两个进程发生死锁。
```

5.4.2 生产者/消费者问题 - 无限缓冲

- ◆ 无限缓冲时,仍然需要对缓冲区数组互斥访问。 设一信号量 s,初值为 1。
- ◆ 无限缓冲时,认为空缓冲总是存在的,因此只考虑"满缓冲数量"即可。设一信号量 full,初值为 0。

semaphore full=0, s=1;

```
void producer()
{ while (true) {
    生产数据;
    semWait(s);
    放入缓冲;
    semSignal(s);
    semSignal(full);
    }
}
```

```
void consumer()
{ while (true) {
    semWait(full);
    semWait(s);
    从缓冲取数;
    semSignal(s);
    消费数据;
    }
}
```

V8图 5.11, V9图 5.14

Question:





设4个信号量代表4种资源: S1—空buf1、S2—满buf1、S3—空buf2、S4—满buf2, 初值 1、0、1、0。

进程get

```
while TRUE
{ semWait(S1);
读数到buf1;
semSignal(S2);
}
```

进程copy

```
while TRUE
{ semWait(S2);
semWait(S3);
复制buf1到buf2;
semSignal(S1);
semSignal(S4);
```

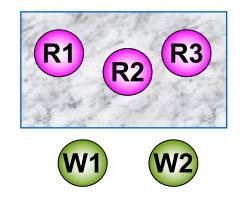
进程put

```
while TRUE
{ semWait(S4);
才印buf2;
semSignal(S3);
}
```

5.7 读者/写者问题 •••••



- ◈ 有一个共享的数据对象:
 - 允许多个读者进程同时读;
 - 一次只允许一个写者进程写;当一个写者正 在写时,不允许其它任何读者或写者同时访 问该共享对象。





5.7.1 读者优先

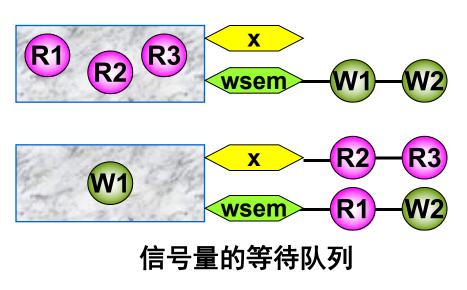
- ◇ 当至少已有一个读者正在读时,随后的读者直接 进入,开始读数据对象。但写者将等待。
- ◇ 当一个写者正在写时,随后到来的读者和写者都等待。
- ◈ 信号量设置:
 - 一次只能让一个写者或一群读者访问数据。设一互斥信号量 wsem, 初值为1。
 - 正在读数据的读者数目由全局变量readcount表示(初值=0),它被多个读者互斥访问。
 (第1个读者需对数据加锁,最后1个读者对数据解锁)为readcount设一互斥信号量x,初值为1。

5.7.1 读者优先



```
void reader()
{ while true {
  semWait(x);
   readcount++;
  if (readcount == 1)
        semWait(wsem);
   semSignal(x);
    读数据对象:
   semWait(x);
   readcount--;
   if (readcount == 0)
        semSignal(wsem);
   semSignal(x);
}}
```

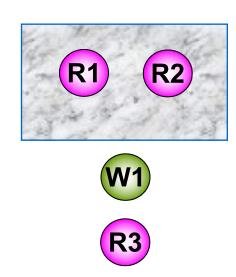
```
■ void writer()
{ while true {
    semWait(wsem);
    写数据对象;
    semSignal(wsem);
} }
```



5.7.2 写者优先



- ◎ 当一个写者声明想写时,不允许新的读者进入数据对象,只需等待已有的读者读完即可开始写。可以避免写者饥饿。
- ◆ 具体实现(V8图5.23, V9图5.26 略)。



Question:



设两个信号量:w表示可拣白子、b表示可拣黑子。 设先拣黑子,w初值0,b初值1。

```
P1:
while TRUE
{ semWait(w);
    拣白子;
    semSignal(b);
}
```

```
P2:
while TRUE
{ semWait(b);
拣黑子;
semSignal(w);
}
```

Question:



 東上有一空盘,允许放一只水果。爸爸可向盘中放桔子, 也可放苹果。儿子专等吃盘中的桔子,女儿专等吃盘中的 苹果。规定当盘空时一次只能放一只水果供吃者取用。 试用信号量实现爸爸、儿子、女儿三个并发进程的同步。

设3个信号量,S表示盘子是否为空(空盘子数),初值为1。 So表示盘中桔子数,初值为0。Sa表示盘中苹果数,初值为0。

```
爸爸:
while TRUE
{ semWait(S);
将水果放入盘中;
if (放入的是桔子)
semSignal(So);
else
semSignal(Sa);
}
```

```
儿子:
while TRUE
{ semWait(So);
从盘中取桔子;
semSignal(S);
吃桔子;
}
```

```
女儿:
while TRUE
{ semWait(Sa);
从盘中取苹果;
semSignal(S);
吃苹果;
}
```

5.5 管程Monitor ****



- ◈ 引入管程: 1974年
 - 各个进程分别对每个可共享的临界资源进行 semWait和semSignal操作,容易发生错误。
 - 在多种程序设计语言中实现了管程(Monitor)。允许用管程锁定任何对象,如变量、数组、链表、 甚至表中每个元素。
 - 管程将共享对象以及能对它进行的所有操作(原本分散在各进程的临界区)集中(封装)在一个模块中。管程本身结构保证各操作的互斥执行。
 - 各进程调用相关操作,可防止进程有意/无意的 互斥/同步错误。

5.5.1 使用信号的管程一组成部分



◈ 管程的组成:

monitor 管程名

声明局部数据和条件变量

```
procedure P1 (...)
{ .... }
procedure P2 (...)
{ .... }

procedure Pn (...)
{ .... }

初始化代码部分
```

只有管程内部的 过程能访问它们

一组对共享的局部数据和条件变量进行操作的过程。 一个进程通过调用某个过程, 进入管程。 管程本身保证互斥,故管程中只能有一个活跃进程。

初始化局部数据

5.5.1 使用信号的管程一条件变量



- ◆ 条件变量condition variable:
 - 表示进程正在等待的资源或原因。只用于维护等待队列,但没有相关联的值。
- ◈ 有两个原语可以操作条件变量:
 - cwait(c): 条件不满足时, 调用 cwait(c) 的进程被 放到条件变量c的等待队列中阻塞。
 - csignal(c):唤醒一个条件变量c的阻塞进程。

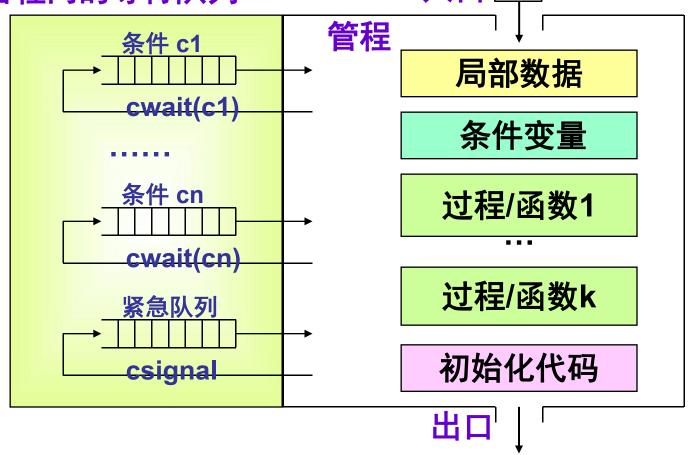
5.5.1 使用信号的管程一内部队列





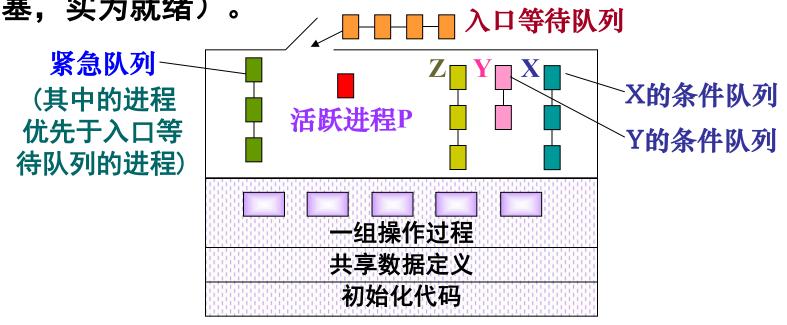
管程内的等待队列

→ 等待进入管程 入口 的进程队列



5.5.1 使用信号的管程一实现互斥/同步

- ▼ 互斥:管程内总是只有一个活跃进程,实现对共享数据/ 资源的互斥使用。不能进入管程的进程排在入口等待队列 中。其它已进入管程的进程处于阻塞状态。
- 同步:不能满足进程Q请求时,cwait(x)使Q进入x的条件队列(阻塞)。另一进程P释放资源时,调用 csignal(x)将Q唤醒。然后Q继续执行,而P进入紧急队列(名为阻塞,实为就绪)。



5.5.1 使用信号的管程一解决生产者/消费者问题

◈ 先定义管程:

monitor boundedbuffer char buffer[N]; int in, out, count; cond notfull, notempty;

```
void append(char x)
{ if (count==N)
        cwait(notfull);
        /*缓冲池满,阻塞*/
    buffer[in]=x;
    in=(in+1)%N;
    count++;
    csignal(notempty);
} //生产者送数
```

count是缓冲池中的有效缓冲数目; notfull, notempty是条件变量。

{ in=0; out=0; count=0; }

51

5.5.1 使用信号的管程一解决生产者/消费者问题

```
void producer()
{ char x;
 while (true)
    { produce(x);
    append(x);
    }
}
```

5.5.2 使用通知和广播的管程(略)

5.6 消息传递



- ◈ 进程间通过"消息传递"交换信息。
- ◈ 消息传递的两个原语:
 - send(P, message)一给进程P发消息message
 - receive(Q, message)一接收来自进程Q的消息



5.6.1 消息传递 一同步

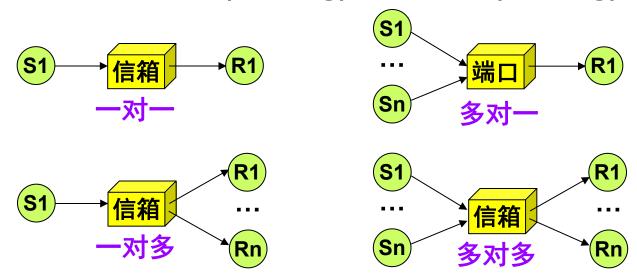


- ◎ 同步:发送者发出消息后,接收者才能接收。
- ◈ 当一个进程执行send()时,该进程可以:
 - 不阻塞,继续执行;
 - 被阻塞, 直到这个消息被接收者接收。
- - 不阻塞,接收已发来的消息或放弃接收,继续执行;
 - 被阻塞,直到所等待的消息到达。
- ◆ 无阻塞式send 和 阻塞式receive 最常用。

5.6.2 消息传递 - 寻址

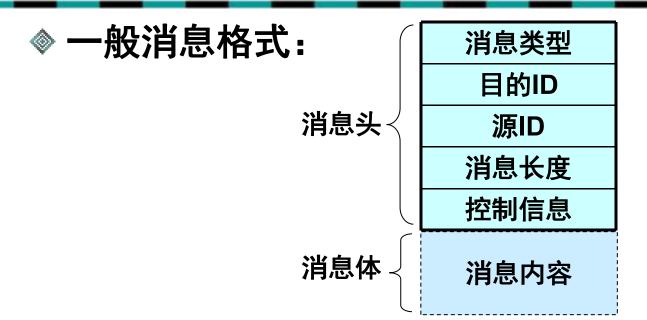


- send 和 receive 如何指明接收者和发送者?
- ◆ 直接寻址: 指明目标进程或源进程的标识ID。
 - 公共服务进程使用receive()时,不指明源进程(隐式)。
- ◈ 间接寻址:通过 信箱 发送和接收消息。
 - 信箱A: send (A, msg), receive(A, msg)



5.6.3 消息传递一消息格式





5.6.4 消息传递一排队原则

- ⑩消息队列: 先入先出(最常见)。
- ⑩ 可指定消息优先级,高级消息先被接收。
- 按收者可检查消息队列,并选择接收哪个消息。

5.6.5 消息传递一互斥 •••••



- ◈ 用消息和两个信箱解决生产者/消费者问题:
 - mayconsume信箱:用作有界缓冲池,存放消息。
 - mayproduce信箱:"空消息"邮箱。最初填满空消息。

空消息数=空缓冲数。只用于同步。

```
void producer()
                         //存放生产者数据的临时缓冲
 message pmsg;
 while (true) {
   receive (mayproduce, pmsg); //接收空消息(空缓冲数减1)。无空消息时阻塞
                  //生产的数据放到临时缓冲pmsg中
   pmsg = produce();
   send (mayconsume, pmsg); //将pmsg放到有界缓冲池mayconsume
                阻塞式receive(), 即无消息时阻塞, 直至消息到来。
void consumer()
  message cmsg;
  while (true) {
   receive (mayconsume, cmsg); //接收一个缓冲。阻塞时表明缓冲池全空
   consume (cmsg);
   send (mayproduce, null);   //发送空消息,实际是使空缓冲数量增1
```

作业:



- ◆ 1、写出信号量定义, semWait和semSignal原语, 以 及用信号量实现互斥的伪代码。(V8图5.3, V9图5.6)
- ② 2、假设一个阅览室有100个座位,没有座位时读者在阅览室外等待;每个读者进入阅览室时都必须在阅览室门口的一个登记本上登记座位号和姓名,然后阅览,离开阅览室时要去掉登记项。每次只允许一个人登记或去掉登记。用信号量操作描述读者的行为。

